BOOK JOB DATA

data product ของงาน: ingest capture เข้า lake พร้อม lineage และ API อ่านอย่างเดียว

Product Requirements (PRD)

รหัสเอกสาร	BJD-DOC-01
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. ปัญหาและเป้าหมาย

2. ผู้ใช้และ persona

3. ขอบเขต

4. ฟีเจอร์หลักและลำดับความสำคัญ

5. ตัวชี้วัดความสำเร็จ

6. Roadmap / phase

7. Decision ที่ต้องยืนยัน

8. ข้อสมมติฐานและความเสี่ยง

การอนุมัติ

แหล่งข้อมูล

Book Job Data — Product Requirements (PRD)

1. ปัญหาและเป้าหมาย

ปัญหา: ข้อมูลงานจาก scraper ต้องเก็บถาวร ตรวจย้อนได้ และให้ระบบอื่นอ่านได้ โดย scraper ไม่ต้องรู้จัก API หรือฐานข้อมูลของระบบปลายทาง และข้อมูลติดต่อบุคคลในไฟล์ capture ต้องไม่หลุดไปถึง consumer

เป้าหมาย: เป็น boundary เดียวของ `job.v1` — รับ capture เข้า lake พร้อม lineage และเปิดอ่านผ่าน API อ่านอย่างเดียว ที่ไม่พึ่ง CSV

เป้าหมายตาม roadmap (สถานะ `proposed`): ภายใน 2026-12-31 cutover hosted lane ของ `job.v1` ไปยัง service ของ repo นี้ ปลดสำเนาใน parent และให้ readiness gate ที่ตรงกับ SLO 8 ชั่วโมงของ `job_postings` บล็อก consumer เมื่อ batch stale หรือยัง reconcile ไม่ได้

2. ผู้ใช้และ persona

Persona	ความต้องการ	หลักฐาน
Operator	หางาน/โปรเจกต์ที่ตรงทักษะจากข้อมูลที่สดและตรวจย้อนได้	ผู้ใช้จริงตาม product card
Consumer ภายใน	`job_client`, opportunity backlog, dashboard leads, `book-sales-jobsdb`	`scraping-data-coverage.yaml`
ผู้ชม portfolio	ดูตัวอย่าง lake-first data product	public repo; ไม่มีตัวเลขผู้ชม **[ต้องยืนยัน]**

3. ขอบเขต

In scope

- ingest CSV จาก `book-job-scraping` (`job_postings.csv`, `matched_jobs.csv`, `leads.csv`, `pipeline.csv`, `exported/jobsdb_jobs.csv`)
- landing (exact bytes) → Bronze `job.v1` (snapshot + history) → manifest + lineage
- API อ่านอย่างเดียวจาก Bronze (local หรือ R2/S3), CSV projection แบบ optional
- privacy allowlist และ redaction อีเมล/เบอร์โทร

Out of scope

- การ scrape (เป็นของ `book-job-scraping`)
- การส่งงานเข้า `opportunity.v1`
- การเขียนเข้าฐานข้อมูล CRM/task ของระบบอื่น, การ refresh ผ่าน API
- consumer ภายนอก/multi-tenant SaaS

4. ฟีเจอร์หลักและลำดับความสำคัญ

ID	ฟีเจอร์	Priority	สถานะ
FR-01	`book_job_data.ingest --input ...` ingest เข้า lake; ข้ามแถวว่าง, ปฏิเสธ non-UTF-8 (exit 2), ไฟล์ซ้ำ land ครั้งเดียว	Must	ทำแล้ว
FR-02	`--dry-run` ตรวจ/normalize โดยไม่เขียน lake	Must	ทำแล้ว
FR-03	`--project-csv` เขียน projection แบบ atomic หลังทุก capture land สำเร็จ	Should	ทำแล้ว
FR-04	Datasets `job_postings`, `job_matches`, `job_leads` + history	Must	ทำแล้ว
FR-05	API `GET /v1/records`, `/v1/history`, `/v1/records/<id>`, `/v1/metadata`, `/healthz`	Must	ทำแล้ว
FR-06	`POST /v1/refresh` ถูกห้าม (403)	Must	ทำแล้ว
FR-07	Token บังคับเมื่อ bind นอก loopback; cache TTL; rate limit	Must	ทำแล้ว
FR-08	อ่าน Bronze จาก R2/S3 โดยตรง (`LAKE_READ_MODE=parquet`, `LAKE_READ_FALLBACK=error`)	Should	ทำแล้ว; verified กับ demo prefix
FR-09	Ingest รายชั่วโมง + แจ้ง stale capture (exit 3)	Should	ทำแล้ว (Windows)
FR-10	Threshold stale สอดคล้อง SLO 8h (`jd-g1`)	Must	ยังไม่ทำ (ค่า default 12h)
FR-11	Cutover Render ไป HEAD ปัจจุบัน + ปลดสำเนา parent (`jd-g2`)	Must	ยังไม่ทำ
FR-12	แก้ README ที่ยังอ้าง opportunity intelligence เป็น Gold product (`jd-g3`)	Could	ยังไม่ทำ

5. ตัวชี้วัดความสำเร็จ

ตัวชี้วัด	เป้าหมาย	ที่มา
`task data:job:readiness` รายงาน ok	7 วันติด	`jd-g4`
Hosted verifier `status=verified` ที่ commit ปัจจุบัน	ผ่าน	`jd-t2`
สำเนาใน parent ถูกลบจาก `legacy_workspace_sources`	ใช่	`jd-t3`
ไม่มีข้อมูลติดต่อหลุดใน Bronze/API	0 กรณีใน test	`tests/test_end_to_end_quality.py`

ไม่มีค่าฐานเรื่องปริมาณงานต่อวันหรือการใช้งาน consumer ใน repository **[ต้องยืนยัน]**

6. Roadmap / phase

Phase	เนื้อหา	สถานะ
P0	contract `job.v1`, ingest, Bronze, API local	เสร็จ
P1	privacy allowlist/redaction, token, R2 read, Render blueprint, ingest รายชั่วโมง	เสร็จ
P2	align SLO, redeploy Render ที่ HEAD, repoint consumers, ปลดสำเนา parent	วางแผน (2026-Q4)

Phase	เนื้อหา	สถานะ
P3	สังเกต readiness 7 วัน	วางแผน

7. Decision ที่ต้องยืนยัน

ID	Decision	สถานะ
D-01	repo นี้เป็น canonical ของ `job.v1` ; สำเนา `book-apps/tools/book-job-data` เป็น compatibility mirror ชั่วคราว	เสนอใน product card **[ต้องยืนยัน]**
D-02	ผู้อนุมัติและวันที่ repoint/ปิด Render service เดิม (การกระทำแบบ destructive)	**[ต้องยืนยัน]** (open question ใน roadmap)
D-03	`job_leads` (มาจาก pipeline) คง internal-only หรือไม่	**[ต้องยืนยัน]**

8. ข้อสมมติฐานและความเสี่ยง

ID	รายการ	ผลกระทบ	การลด
R-01	สองสำเนา drift (โค้ด `src/` ต่างกันแล้ว)	bug fix/privacy fix ไม่ถึง service เดิม	cutover แล้วลบสำเนา (`jd-t3`)
R-02	Render Free sleep และ filesystem ชั่วคราว	API ช้าครั้งแรก/ไม่มีข้อมูล local	R2 เป็นแหล่งถาวรเดียว
R-03	Scraper หยุด → capture stale	consumer ได้ข้อมูลเก่า	alert stale (exit 3) + readiness gate
R-04	Redaction พลาดรูปแบบเบอร์/อีเมลใหม่	ข้อมูลส่วนบุคคลหลุด	allowlist + edge-case tests; ทบทวนเป็นระยะ
R-05	ToS ของ job board ต้นทาง	ต้องหยุดเก็บบางแหล่ง	อยู่ในความรับผิดชอบของ `book-job-scraping` **[ต้องยืนยัน]**
A-01	`solo-empire-data-lake` pin เดียวกันกับ repo `book-*-data` อื่น	อัปเดตต้องทำพร้อมกัน	backlog P1

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Product owner (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `docs/UPGRADE-PLAN.md`
- `src/book_job_data/ingest.py`
- `src/book_job_data/api.py`
- `scripts/scheduled_ingest.py`
- `tests/test_end_to_end_quality.py`
- `DOCPACK/00-product-card.md`

- `(solo-empire) repository-catalog/roadmaps/data-scrapers.yaml` (`jd-g1` – `jd-g4`, `jd-t1` – `jd-t5`)
- `(solo-empire) systems/ai-data/scraping-data-coverage.yaml`