BOOK JOB DATA

data product ของงาน: ingest capture เข้า lake พร้อม lineage และ API อ่านอย่างเดียว

System Architecture

รหัสเอกสาร	BJD-DOC-02
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. Context diagram

2. Components

3. เส้นทางข้อมูล (sources → ingestion → lake → API/consumers)

4. Tech stack

5. Data stores

6. Integrations

7. Deployment topology

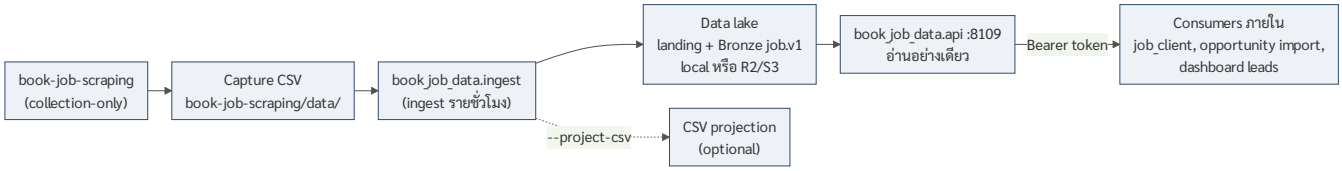
8. ADR สำคัญ

การอนุมัติ

แหล่งข้อมูล

Book Job Data — System Architecture

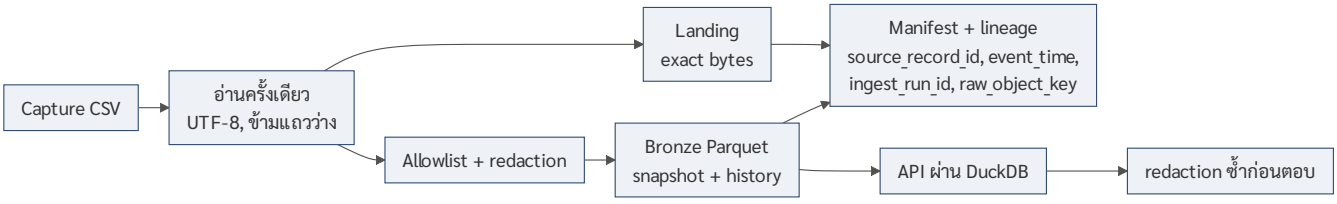
1. Context diagram



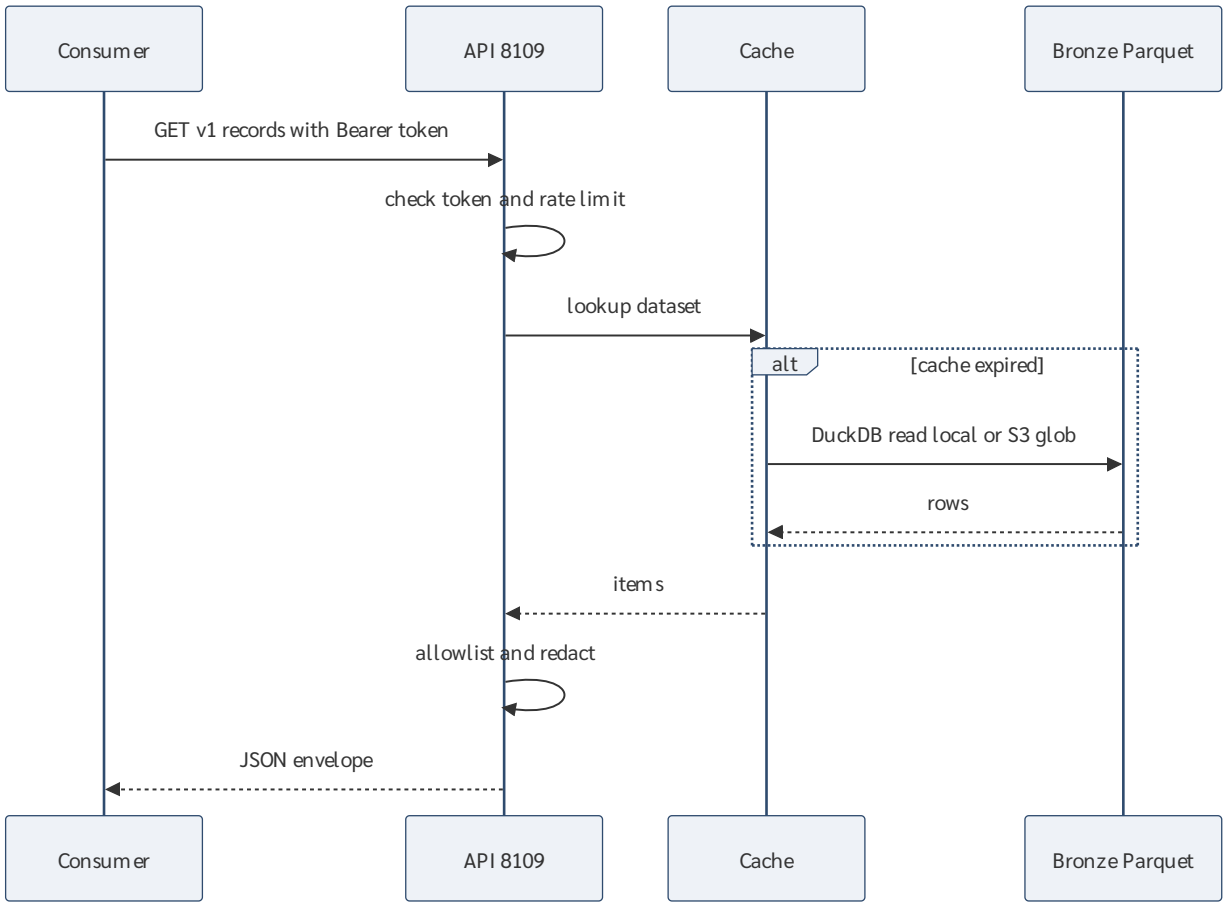
2. Components

Component	ไฟล์	หน้าที่
Config	`src/book_job_data/config.py`	ค่าจาก environment, contract (`job.v1`, `jobs`, privacy `internal`, retention `operational`), datasets
Ingest CLI	`src/book_job_data/ingest.py`	อ่าน capture ครั้งเดียว, validate, dedupe input, จำแนก dataset จากชื่อไฟล์, เรียก lake
Lake adapter	`src/book_job_data/lake.py`	เขียน landing/Bronze ผ่าน `solo-empire-data-lake` (pinned commit) และอ่านกลับ
Privacy	`src/book_job_data/privacy.py`	`ALLOWED_FIELDS` + `redact_text` (อีเมล, เบอร์โทรรวมรูปแบบไทย) ใช้ทั้ง ingest และ API
Store	`src/book_job_data/store.py`	`stable_job_id`, `canonical_url`, CSV projection แบบ atomic
API	`src/book_job_data/api.py`	HTTP server (stdlib), auth, cache, rate limit, DuckDB อ่าน Parquet
Scheduled ingest	`scripts/scheduled_ingest.py`, `ops/windows/scheduled-ingest.ps1`	tick รายชั่วโมง, log ลง `data/ingest.log`, stale alert
R2 parity verifier	`scripts/r2_parity.py`	เขียน demo prefix แล้วตรวจ replay/manifest/idempotency

3. เส้นทางข้อมูล (sources → ingestion → lake → API/consumers)



Input file	Dataset
`job_postings.csv` และไฟล์อื่นที่ไม่เข้าเงื่อนไขด้านล่าง	`job_postings`
`matched_jobs.csv`	`job_matches`
`leads.csv`, `pipeline.csv`, ไฟล์ที่ชื่อมี `jobsdb_jobs`	`job_leads`



4. Tech stack

- Python ≥ 3.11 (Docker `python:3.12-slim`, CI 3.12)
- `[lake]` extra: `duckdb>=1.1,<2`, `pyarrow>=14,<24`, `solo-empire-data-lake[lake]` pinned commit `4c24c66`
- HTTP server จาก standard library (ไม่มี web framework)
- ไม่มี dependency หลักใน `dependencies = []`; dev tools `pytest`, `ruff` ติดตั้งแยก

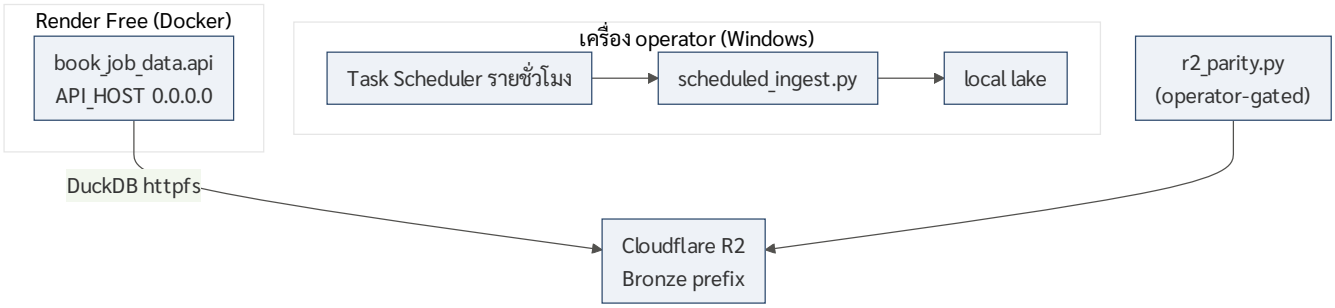
5. Data stores

Store	ที่ตั้ง	เนื้อหา
Landing	`SOLO_EMPIRE_DATA_LAKE_URI` (local path หรือ `s3://`)	exact capture bytes เป็น replay evidence
Bronze	lake เดียวกัน	Parquet `job.v1` ต่อ dataset + history + manifest
Lineage	`lake_lineage.json`	ข้อมูลที่ `/v1/metadata` ส่งกลับ
Local data	`data/` (ignored)	`ingest.log`, CSV projection
R2 (hosted)	bucket/prefix ที่กำหนดผ่าน env	แหล่งถาวรเดียวของ hosted lane

6. Integrations

ระบบ	ทิศทาง	Contract
`book-job-scraping`	ขาเข้า (ไฟล์)	CSV ใน `data/`; ไม่มีการเรียก API
`solo-empire-data-lake`	library	pinned commit; MIT
Cloudflare R2	storage	S3 API ผ่าน `DATA_LAKE_S3_ENDPOINT`
Consumers ภายใน	ขาออก (HTTP)	`job.v1` envelope; `job_client` fallback อ่าน Bronze ด้วย DuckDB
Parent readiness	ตรวจ	`task data:job:readiness` (`infra/scripts/data_lake/job_data_readiness.py`)

7. Deployment topology



- Local: ingest เขียน local lake; API local bind loopback
- Hosted: Render อ่าน R2 อย่างเดียว ไม่ ingest; ยังไม่มีขั้นตอนอัตโนมัติที่ส่ง capture ใหม่เข้า R2 prefix ของ production **[ต้องยืนยัน]**
- Parallel service ใน Render verified 2026-08-09 ที่ commit `6942dbf` กับ demo prefix; service เดิมของ parent ยังเป็นตัวหลัก **[ต้องยืนยัน]**

8. ADR สำคัญ

ID	การตัดสินใจ	เหตุผล	สถานะ
ADR-01	Scraper เป็น collection-only; ส่งต่อด้วยไฟล์	แยก boundary ไม่ให้เขียน DB ของกันและกัน	ใช้อยู่
ADR-02	API อ่าน Bronze เท่านั้น ไม่เปิด CSV, refresh ถูกห้าม	consumer ไม่ผูกกับ projection	ใช้อยู่
ADR-03	Redaction สองชั้น (ingest + response)	กันข้อมูลติดต่อหลุดแม้ Bronze เก่า	ใช้อยู่
ADR-04	`LAKE_READ_FALLBACK=error`	fail closed ไม่สลับแหล่งเงียบ ๆ	ใช้อยู่
ADR-05	ใช้ public `solo-empire-data-lake` pinned commit	รันนอก parent ได้	ใช้อยู่
ADR-06	repo นี้เป็น canonical, สำเนา parent เป็น mirror	ลด drift	**[ต้องยืนยัน]**

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Solution Architect (Book Dev)	รอพิจารณา	—	_
Product owner (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `pyproject.toml`
- `Dockerfile`
- `render.yaml`
- `src/book_job_data/config.py`
- `src/book_job_data/ingest.py`
- `src/book_job_data/api.py`
- `src/book_job_data/privacy.py`
- `scripts/scheduled_ingest.py`
- `ops/windows/scheduled-ingest.ps1`
- `(solo-empire) operations/evidence/BOOK-JOB-DATA-RENDER-CUTOVER.md`
- `(solo-empire) systems/ai-data/scraping-data-coverage.yaml`