BOOK JOB DATA

data product ของงาน: ingest capture เข้า lake พร้อม lineage และ API อ่านอย่างเดียว

Runbook การติดตั้งและดูแลระบบ

รหัสเอกสาร	BJD-DOC-04
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. Environments

2. Build และทดสอบ

3. Ingest และ scheduled runs

4. Backfill / replay

5. Deploy (Render)

6. Config และ secret (ชื่อตัวแปรเท่านั้น)

7. Health check

8. Failure handling / troubleshooting

9. Rollback

10. Backup / restore

การอนุมัติ

แหล่งข้อมูล

Book Job Data — Runbook การติดตั้งและดูแลระบบ

1. Environments

Environment	Lake	API	สถานะ
Local dev	local path (`SOLO_EMPIRE_DATA_LAKE_URI`)	loopback `127.0.0.1:8109`	ใช้งานได้
Local scheduled (Windows)	local path	—	ingest รายชั่วโมง
CI (GitHub Actions)	temp lake ใน test	—	ใช้งานได้
Hosted (Render Free)	R2 `s3://` prefix	`0.0.0.0`, token บังคับ	parallel service verified 2026-08-09 ที่ `6942dbf`; สถานะปัจจุบัน **[ต้องยืนยัน]**
Compatibility mirror (parent)	—	Render service เดิมจากสำเนาใน parent	ยังเป็นตัวหลักจนกว่า cutover **[ต้องยืนยัน]**

2. Build และทดสอบ

```
python -m pip install -e ".[lake]" pytest ruff
ruff check .
python -m pytest -q -rs
python -m book_job_data.ingest --input fixtures/job_postings.csv --dry-run
```

E2E contract gate จาก parent (ต้องมี `pyarrow`, `duckdb`):

```
python infra/tests/job_data_e2e_test.py
```

3. Ingest และ scheduled runs

```
# ingest □□□□□□□□□□□ (□□□□□□□□ default □□□ sibling book-job-scraping/data/ □□□□□□□□□□□□□ --input)
python -m book_job_data.ingest --input <path>/job_postings.csv --data-lake-uri <lake path>
# □□□□□ CSV projection
python -m book_job_data.ingest --input <path>/job_postings.csv --data-lake-uri <lake path> --project-csv
```

Windows Task Scheduler (รายชั่วโมง, idempotent):

```
.\ops\windows\scheduled-ingest.ps1 install
.\ops\windows\scheduled-ingest.ps1 status
.\ops\windows\scheduled-ingest.ps1 remove
```

ต้องสร้าง `.venv` และติดตั้ง `.[lake]` ก่อน `install` ผลแต่ละ tick ต่อท้ายใน `data/ingest.log`

4. Backfill / replay

- Backfill: ส่ง capture CSV เก่าผ่าน `--input` (ซ้ำได้หลายไฟล์); ไฟล์ที่ bytes เดิมจะใช้ batch id เดิม
- Replay: landing เก็บ exact bytes จึงสร้าง Bronze ใหม่ได้จาก landing; ใช้ฟังก์ชัน replay ของ `solo-empire-data-lake` **[ต้องยืนยัน]** ว่ามีคำสั่ง CLI สำหรับ replay ทั้ง lake หรือไม่
- ไม่ควร backfill เข้า R2 production prefix โดยไม่ได้รับอนุมัติ; `scripts/r2_parity.py` เขียนได้เฉพาะ demo prefix ที่จำกัด

5. Deploy (Render)

1. สร้าง Web Service จาก repo นี้ด้วย Blueprint `render.yaml` (Docker, Free, health `/healthz`)
2. ตั้งค่า secret ใน Render Environment (ไม่ใส่ใน YAML)
3. Deploy แล้วรัน hosted verifier จาก parent:

```
BOOK_JOB_DATA_URL=https://<service>.onrender.com \
BOOK_JOB_DATA_API_TOKEN=<from secret manager> \
PYTHONPATH=<solo-empire>/infra/scripts \
  <solo-empire>/.venv/bin/python <solo-empire>/infra/scripts/data_lake/hosted_job_api_e2e.py
```

ผลที่คาดหวัง: `status=verified`, `storage_model=lake_first_job_bronze_s3_duckdb`, `records_source_kind=bronze_s3_parquet`

การสร้าง service, ตั้ง environment, deploy และ repoint consumer ต้องได้รับอนุมัติจากเจ้าของก่อนทุกครั้ง ขั้นตอน cutover เต็มอยู่ใน `(solo-empire) operations/evidence/BOOK-JOB-DATA-RENDER-CUTOVER.md`

6. Config และ secret (ชื่อตัวแปรเท่านั้น)

ตัวแปร	ใช้ทำอะไร	Secret
`SOLO_EMPIRE_DATA_LAKE_URI` (`DATA_LAKE_URI`)	ที่ตั้ง lake (path หรือ `s3://`)	ไม่ (แต่ไม่เก็บค่า production ใน Git)
`DATA_LAKE_S3_ENDPOINT`	endpoint R2	ไม่
`AWS_ACCESS_KEY_ID`, `AWS_SECRET_ACCESS_KEY`	credential R2	ใช่
`BOOK_JOB_DATA_API_TOKEN` (`API_READ_TOKEN`)	Bearer token ของ API	ใช่
`API_HOST`, `PORT` / `API_PORT`	bind address/port (default `127.0.0.1:8109`)	ไม่
`LAKE_READ_MODE`, `LAKE_READ_FALLBACK`	`parquet` / `error`	ไม่
`BOOK_JOB_DATA_CACHE_TTL_SECONDS`, `BOOK_JOB_DATA_RATE_LIMIT_PER_MINUTE`	cache / rate limit	ไม่
`BOOK_JOB_SCRAPING_DATA_DIR`	ที่ตั้ง capture CSV	ไม่
`BOOK_JOB_DATA_MAX_CAPTURE_AGE_HOURS`	threshold stale ของ scheduled ingest (default 12)	ไม่
`DATA_DIR`, `FIXTURES_DIR`, `STALE_AFTER_HOURS`, `REQUEST_TIMEOUT_SECONDS`	ค่าทั่วไป	ไม่

ตัวแปร	ใช้ทำอะไร	Secret
`ALLOW_REFRESH`, `ALLOW_EXTERNAL_WRITES`, `ALLOW_PAID_PROVIDERS`, `FREE_ONLY`	safety flags	ไม่
`DATA_LAKE_CLOUD_WRITE_ENABLED`	อนุญาตการเขียน R2 ใน verifier	ไม่

7. Health check

```
curl -fsS http://127.0.0.1:8109/healthz                 # □□□□□□□□ lake
curl -fsS -H "Authorization: Bearer $BOOK_JOB_DATA_API_TOKEN" http://127.0.0.1:8109/v1/metadata
task data:job:readiness                                 # □□□ parent: reconcile batch + freshness
.\ops\windows\scheduled-ingest.ps1 status               # LastTaskResult
```

สัญญาณปกติ: `/v1/metadata` มี `dataset_counts` > 0, readiness ok, `LastTaskResult` = 0

8. Failure handling / troubleshooting

อาการ	สาเหตุที่เป็นไปได้	การแก้
API ไม่ start บน Render	ไม่ได้ตั้ง `BOOK_JOB_DATA_API_TOKEN` ขณะ bind `0.0.0.0`	ตั้ง secret แล้ว redeploy
401	token ไม่ถูกต้อง/ไม่มี	ตรวจ header Bearer
429	เกิน rate limit	รอ 1 นาที หรือปรับ `BOOK_JOB_DATA_RATE_LIMIT_PER_MINUTE`
`data_status=not_loaded` ใน `/healthz`	ยังไม่มีการเรียก endpoint ข้อมูล	ปกติ; เรียก `/v1/records` เพื่อ warm
อ่าน R2 ล้ม (fallback `error`)	endpoint/credential/prefix ผิด	ตรวจ env; ห้ามเปิด fallback เพื่อกลบปัญหา
ingest exit 2	non-UTF-8 input หรือ crash	ดู `data/ingest.log`; แก้ encoding ที่ scraper
exit 3 + `ALERT stale scraper capture`	scraper หยุดหรือไฟล์หาย/เก่า	ตรวจ task ของ `book-job-scraping`
ingest ไม่เขียนอะไร	capture ไม่มีแถวจริง หรือ bytes ซ้ำ batch เดิม	ปกติสำหรับไฟล์ซ้ำ; ตรวจ scraper ถ้าไฟล์ว่าง
tick ค้าง	I/O หรือ lock	`faulthandler` dump ใน log หลัง 900 วินาที
ผลต่างระหว่าง public กับ parent mirror	drift ของสองสำเนา	ใช้ repo นี้เป็นอ้างอิง; ติดตาม `jd-t3`

9. Rollback

- Render: redeploy commit ก่อนหน้าจาก Render Dashboard; service เดิมของ parent ยังอยู่เป็นทางถอยระหว่าง cutover
- Consumer: ชี้ URL กลับไป service เดิม (การเปลี่ยน URL ของ consumer ต้องได้รับอนุมัติ)
- ข้อมูล: Bronze เป็น append + history; rollback คือ replay จาก landing ไม่ใช่ลบ batch **[ต้องยืนยัน]** ขั้นตอนลบ batch ที่ผิด
- Contract: เปลี่ยนแบบ breaking ต้องออกเวอร์ชันใหม่ ไม่แก้ `job.v1` ในที่

10. Backup / restore

- R2 คือแหล่งถาวรของ hosted lane; นโยบาย versioning/backup ของ bucket **[ต้องยืนยัน]**
- Local lake: ไม่มีขั้นตอน backup ใน repository **[ต้องยืนยัน]**
- Restore: ingest capture CSV ใหม่หรือ replay landing bytes; ตรวจด้วย `task data:job:readiness`

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
DevOps / Operator (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `render.yaml`
- `Dockerfile`
- `src/book_job_data/config.py`
- `src/book_job_data/ingest.py`
- `src/book_job_data/api.py`
- `scripts/scheduled_ingest.py`
- `scripts/r2_parity.py`
- `ops/windows/scheduled-ingest.ps1`
- `(solo-empire) operations/evidence/BOOK-JOB-DATA-RENDER-CUTOVER.md`
- `(solo-empire) infra/tasks/data.yml` (`data:job:readiness`)