BOOK JOB DATA

data product ของงาน: ingest capture เข้า lake พร้อม lineage และ API อ่านอย่างเดียว

Product Card

รหัสเอกสาร	CARD-book-job-data-public
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. สรุปคุณค่าในหนึ่งประโยค

2. ปัญหาและผู้ใช้เป้าหมาย

3. สิ่งที่ทำได้จริงตอนนี้

4. หลักฐานสถานะ

5. คุณค่าและจุดต่าง

6. ช่องว่างสำคัญ

7. คำตัดสิน

8. ขั้นต่อไป

การอนุมัติ

แหล่งข้อมูล

Book Job Data — Product Card

1. สรุปคุณค่าในหนึ่งประโยค

รับ capture จาก `book-job-scraping` เข้า data lake (landing → Bronze `job.v1`) พร้อม lineage และให้ API อ่านอย่างเดียว ทำให้ข้อมูลงานตรวจย้อนได้และไม่ผูกกับตัว scraper

2. ปัญหาและผู้ใช้เป้าหมาย

- ปัญหา: ข้อมูลงานจาก scraper ต้องเก็บถาวร ตรวจย้อน และให้ระบบอื่นอ่านได้โดยไม่เขียน DB ของกันและกัน
- ผู้ใช้: operator และ consumer ภายใน Solo Empire (เช่น `job_client`)

3. สิ่งที่ทำได้จริงตอนนี้

- `book_job_data.ingest`: รับ CSV, ข้ามแถวว่าง, ปฏิเสธ non-UTF-8, กันไฟล์ซ้ำ, `--dry-run`, `--project-csv` แบบ atomic
- datasets `job_postings`, `job_matches`, `job_leads` (+ history)
- `book_job_data.api` (:8109) อ่าน Bronze เท่านั้น, refresh ถูกห้าม; มี privacy redaction
- Dockerfile + `render.yaml` (free plan, health `/healthz`), Windows scheduled ingest รายชั่วโมง

4. หลักฐานสถานะ

รายการ	ค่า (ตรวจจาก repository)
Stack	Python
Commits	18 (แรก 2026-08-08 → ล่าสุด 2026-10-01)
Source	14 ไฟล์ / 1,453 บรรทัด
Tests	5 ไฟล์
CI	1 workflow
Deploy config	`render.yaml`, `Dockerfile`
Live URL	ไม่มี
README	206 บรรทัด (`book-job-data`)
โครงสร้างซ้ำ (template family)	1 repo ที่มี structure signature เดียวกัน

repo นี้คือ public Track B (remote `book-job-data.git`) เป็น superset ของสำเนาใน parent ที่ `book-apps/tools/book-job-data` (สำเนานั้นไม่มี CI, Dockerfile, `render.yaml` และ test 2 ไฟล์ และโค้ด `src/` ต่างกัน)

5. คุณค่าและจุดต่าง

- เป็นครึ่งหลังของ job pipeline ที่เป็น Tier A — ทำให้ข้อมูลงานใช้ซ้ำได้โดยไม่ผูกกับ scraper
- ใช้ `solo-empire-data-lake` แบบ public pin จึงรันนอก parent ได้

- มุมรายได้: ไม่มีทางตรง; คุณค่าอยู่ที่การหางาน/หาลูกค้าของเจ้าของ **[สมมติฐาน]**

6. ช่องว่างสำคัญ

- สองสำเนา (public กับ parent) โค้ดต่างกันแล้ว เสี่ยง drift
- ยังไม่ยืนยันว่า Render service ทำงานอยู่ **[ต้องยืนยัน]**
- ไม่มี consumer ภายนอก

7. คำตัดสิน

`invest` — เป็นส่วนสำคัญของ job pipeline ที่มีผู้ใช้จริง (เจ้าของ) มี test, CI และ deploy config จึงลงทุนต่อร่วมกับ `book-job-scraping` ให้ repo นี้เป็น canonical และให้สำเนาใน parent เป็นเพียง compatibility mirror จะลดเป็น `showcase` ถ้าเลิกใช้ job pipeline

8. ขั้นต่อไป

1. ประกาศให้ repo นี้เป็น canonical และวางแผนให้ parent copy ตาม (หรือเลิกใช้)
2. ตรวจสถานะ Render service และ `task data:job:readiness`
3. บันทึก CSV contract ร่วมกับ `book-job-scraping`

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Product owner (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `render.yaml`
- `Dockerfile`
- `src/book_job_data/api.py`
- `src/book_job_data/ingest.py`
- `(book-dev) bookchaowalit/book-apps/tools/book-job-data/`